

Relatório de Evolução — Sprint 3

Disciplina: Prompt and Artificial Intelligence | Curso: Ciência da Computação

7.1 Resumo da evolução

Nas Sprints 1 e 2, o núcleo conversacional do ChargeGrid Intelligence foi implementado de forma manual, usando chamadas diretas ao endpoint `chat.completions` da OpenAI. O fluxo de tool calling (função `calcular_expressao`), o histórico de mensagens e a lógica de guardrails de escopo eram controlados por código Python escrito à mão, com o histórico de conversa mantido apenas como uma lista em memória, reiniciada a cada execução de teste.

Na Sprint 3, esse núcleo foi refatorado para o OpenAI Agents SDK. A orquestração do agente, das ferramentas e da memória passou a ser gerenciada pelo framework (Agent, Runner e `SQLiteSession`), e a barreira de escopo baseada apenas em instrução textual do system prompt foi substituída por dois guardrails estruturais — um agente verificador de entrada (escopo e prompt injection) e um agente verificador de saída (conselho profissional indevido) — com saída estruturada via Pydantic. Também foi adicionada uma etapa de comparação entre configurações de modelo (`temperature`, `top_p`, `max_tokens`), registrada em `relatorio_modelos.md`.

7.2 Refatoração

Framework escolhido e motivo

Foi escolhido o OpenAI Agents SDK. Principais motivos: é a opção oficial da própria OpenAI, com suporte nativo a tool calling, guardrails de entrada/saída e sessões de memória (`SQLiteSession`) sem exigir bibliotecas adicionais de orquestração; a API é declarativa e integra-se diretamente ao modelo já usado nas Sprints 1 e 2 (`gpt-4o-mini`), reduzindo o esforço de migração.

Principais componentes utilizados

- Agent — define o agente principal (`instructions`, `tools`, `guardrails`, `model`, `model_settings`).
- Runner — executa o agente e gerencia o ciclo de vida da conversa (`tool calls`, `guardrails`, `sessão`).
- `function_tool` — expõe `calcular_expressao` como ferramenta do agente.
- `input_guardrail` / `output_guardrail` — dois agentes verificadores independentes, com saída estruturada (Pydantic: `AnaliseEntrada`, `AnaliseSaida`).
- `SQLiteSession` — memória persistente por sessão (`session_id`), usada na demonstração de 3 turnos e nas baterias de teste.
- `ModelSettings` — parametrização de `temperature`, `top_p` e `max_tokens` por configuração testada.

Vantagens encontradas

- Menos código de infraestrutura: o Runner assume o loop de tool calling que antes era manual.
- Guardrails como agentes separados, com saída estruturada, tornam a decisão de bloqueio auditável e testável isoladamente do agente principal.
- Memória por sessão passa a ser persistente em disco, em vez de uma lista Python volátil.

Limitações e trade-offs identificados

- Cada turno passa a custar pelo menos 3 chamadas de modelo (`guardrail de entrada`, `agente principal`, `guardrail de saída`), aumentando latência e tokens.
- Depuração fica mais difícil: um bloqueio pode se originar no `guardrail de entrada`, no agente principal ou no `guardrail de saída`.

- O SDK depende, por padrão, de conectividade com o serviço de tracing da OpenAI; em ambientes de rede restrita isso gera warnings não-fatais que podem mascarar o diagnóstico de erros reais.

7.3 Comparativo antes × depois

Métrica	Sprint 1 e 2	Sprint 3
Arquitetura	Manual (chat.completions)	OpenAI Agents SDK
Modelo	gpt-4o-mini	gpt-4o-mini
Framework	Nenhum (loop manual)	OpenAI Agents SDK 0.22.3
Memória	Lista em memória (resetada por teste)	SQLiteSession (persistência por sessão)
Nota funcional (%)	90,0	63,3
Nota memória (%)	N/A	100,0
Nota segurança (%)	N/A	50,0
Latência média (s)	N/A	5,0
Tokens/turno	N/A	1959
Guardrails	Não	Sim (entrada + saída)
Persistência de sessão	Não	Sim (.db SQLite)
Injeção de prompt	Vulnerável (instrução no prompt)	Bloqueada (guardrail estrutural)

N/A: métrica não medida de forma sistemática nas Sprints 1 e 2.

7.4 Problemas encontrados e soluções

Problema 1 — Falha de conexão por chave de API malformada

Problema: as chamadas à API falhavam com "Connection error", mascarando o erro real: a variável `api_key`, ao ser carregada do Colab Secrets/.env, vinha com caracteres de quebra de linha (`\r\n`) grudados no final, o que invalidava o header HTTP Authorization antes mesmo da requisição sair pela rede (LocalProtocolError: Illegal header value).

Alternativas consideradas: (a) reconfigurar a forma de armazenar a credencial; (b) ignorar e tratar como instabilidade de rede; (c) sanitizar o valor lido antes de usá-lo.

Solução adotada: aplicar `.strip()` ao valor de `api_key` (e de qualquer outra chave) imediatamente após o carregamento, antes de passá-lo a `set_default_openai_key`.

Justificativa: é a correção mais simples e segura — não exige mudar onde/como a credencial é armazenada e elimina a causa raiz independentemente da origem (Colab Secrets ou arquivo .env).

Problema 2 — Falso positivo no guardrail de saída

Problema: o teste funcional F4 (Peak Shaving, redução de potência via software) foi bloqueado pelo guardrail de saída, que classificou a resposta como "conselho técnico indevido", quando na verdade se trata de uma ação operacional normal do ChargeGrid (controle de potência dos carregadores via software).

Alternativas consideradas: (a) remover o guardrail de saída; (b) afrouxar de forma genérica as regras do verificador; (c) refinar o prompt do agente verificador para excluir explicitamente esse tipo de ação.

Solução adotada: ajustar as instruções do agente verificador de saída para excluir explicitamente o controle de potência via software (Peak Shaving/Load Balancing) da categoria de conselho profissional indevido, mantendo o bloqueio para orientação jurídica, financeira e elétrica de hardware.

Justificativa: preserva o propósito do guardrail (impedir conselho jurídico/financeiro/elétrico perigoso) sem sacrificar respostas funcionais legítimas do domínio do produto.

7.5 Divisão da equipe

Nome	RM	Principal responsabilidade
Lucca Bertolini	569552	Comparação entre os Modelos + relatório_modelo.md
Diego de Oliveira Brandão	569773	Empacotamento + Verificação Final + Organização do Repo
Raphaello Caffettani	572334	Casos de teste de segurança + Guardrail
Cristhian Henrique Clementino	574117	Setup do projeto, refatoração do núcleo com o framework novo + memória por sessão
Fabio Pena Vieira	570441	Relatório de Evolução em PDF